

# 03GIAR Probabilidad y Estadística.

## Actividad 1. Evidencia 2

2024@LUCIA, RODRIGUEZ, Y8678805E

Fecha de entrega: 21/12/2024

### Ejercicio 1 (Momentos centrales y dispersión sobre datos)

```
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.4.2
```

```
head(diamonds) ##Instalo libreria necesaria para analizar variable
```

```
## # A tibble: 6 x 10
##   carat cut      color clarity depth table price     x     y     z
##   <dbl> <ord>    <ord> <ord>   <dbl> <dbl> <int> <dbl> <dbl> <dbl>
## 1  0.23 Ideal    E     SI2      61.5    55   326  3.95  3.98  2.43
## 2  0.21 Premium  E     SI1      59.8    61   326  3.89  3.84  2.31
## 3  0.23 Good     E     VS1      56.9    65   327  4.05  4.07  2.31
## 4  0.29 Premium  I     VS2      62.4    58   334  4.2   4.23  2.63
## 5  0.31 Good     J     SI2      63.3    58   335  4.34  4.35  2.75
## 6  0.24 Very Good J     VVS2     62.8    57   336  3.94  3.96  2.48
```

```
vc<-diamonds$clarity
#La variable "Clarity" es una variables discreta,
#ya que representa la claridad de un diamante.
#Representa niveles categoricos.
v2<-table(vc)      #Creo una tabla de valores
v2
```

```
## vc
##   I1    SI2    SI1    VS2    VS1    VVS2    VVS1     IF
##   741   9194  13065  12258   8171   5066   3655   1790
```


```
# Defino vector con etiquetas para la variable "Clarity"
lv2<-c("I1","SI2","SI1","VS2","VS1","VVS2","VVS1","IF")
df1<-data.frame(lv2,v2)  #Creo un data frame
```

```
# Diagrama de barras, uso este grafico ya que es ideal para representar datos
# discretos. Permite visualizar frecuencias por categorias y comparar valores.
barplot(height=df1$Freq, names=df1$lv2,las=2,
```

```

main="Limpieza del diamante",#titulo del grafico
ylab="Valores",
xlab="Categorias",
ylim=c(0,16000),
##4 opciones para las barras y leyenda
col=c("pink","red","lightblue","purple","violet","orange","yellow","green"),
legend=rownames(df1),
density=c(3,9,17,35,19),
angle=c(10,25,60,41,80),)

```



#El siguiente diagrama de barras nos muestra como se distribuyen los datos por los niveles según el tipo indicado. Nos muestra que las categorías SI1 y VS2, que representan diamantes, de calidad moderada son los mas frecuentes, con valores entre 10000-15000, y por tanto podemos observar que para este conjunto de datos, las categorías I1, que representan a aquellos con calidad baja, y a los incluidos en la categoría IF, que representan a los de mas alta calidad, que son los menos frecuentes. Realizo calculo de estadisticos, en el caso de esta variable por su definicion discreta, no seria aplicable calcular, por ejemplo, medidas como la media aritmetica, para este conjunto de datos. Por esto evaluare su moda.

```
## moda de clarity: SI1
```

```
## [1] "SI1"
```

#Como podemos ver definiendo la moda de esta variable, nos confirma lo visto en el grafico anterior, donde la mayor frecuencia esta en la categoria SI1. Podemos tambien verla graficamente con el Diagrama de Pareto, por ejemplo:

```
## [1] "SI1"


## Installing package into 'C:/Users/lulia/AppData/Local/R/win-library/4.4'
## (as 'lib' is unspecified)

## package 'qcc' successfully unpacked and MD5 sums checked
##
## The downloaded binary packages are in
## C:\Users\lulia\AppData\Local\Temp\RtmpSOYOIy\downloaded_packages

## Warning: package 'qcc' was built under R version 4.4.2

## Package 'qcc' version 2.7

## Type 'citation("qcc")' for citing this R package in publications.
```



```
##
## Pareto chart analysis for table(diamonds$clarity)
##      Frequency   Cum.Freq.   Percentage Cum.Percent.
```

```

##  SI1  13065.000000 13065.000000  24.221357  24.221357
##  VS2  12258.000000 25323.000000  22.725250  46.946607
##  SI2  9194.000000 34517.000000  17.044865  63.991472
##  VS1  8171.000000 42688.000000  15.148313  79.139785
##  VVS2 5066.000000 47754.000000   9.391917  88.531702
##  VVS1 3655.000000 51409.000000  6.776047  95.307749
##  IF   1790.000000 53199.000000  3.318502  98.626251
##  I1   741.000000 53940.000000  1.373749 100.000000

```

*#Graficamente confirmamos, lo expuesto anteriormente, siendo los diamantes con caracteristicas SI1, #los de mayor frecuencia.*

```

#Variable aleatoria continua "Carat"
v3<-diamonds$carat

```


*#Si realizamos un histograma los datos se muestran como una distribucion que refleja la frecuencia #de los distintos pesos, valorados en Quilates, de la variable "Carat", a simple vista podemos #observar que aquellos que presentan mayor frecuencia, seran los valorados, entre 0 y 1.*

```

#Hacemos un histograma basico
hist (v3, main = "Peso de los diamantes en Quilates",
      #xlab = "$",
      #ylab="Frecuencia",
      #prob = TRUE,
      col="lightpink",
      #ylim = c(0,0.44)
)

```


## Peso de los diamantes en Quilates



#Si realizamos una transformacion a los datos con la raiz cuadrada, se expone una reduccion  
#en la asimetria de la distribucion, lo que facilita el analisis y la interpretacion de los  
#datos al acercarlos mas a una distribucion simetrica. Esto es util, ya que al aplicar  
#la raiz cuadrada, los valores grandes se reducen proporcionalmente mas que los pequeños,  
#obteniendo un sesgo disminuido. Y asi creando graficamente, una opcion visualmente mas clara.

#Hacemos un histograma pero aplicamos raiz cuadrada a "v3"

```
hist (sqrt(v3),  
      breaks=85, main = "Peso",  
      #xlab = "$",  
      ylab="Frecuencia",  
      prob = TRUE, col="lightpink",  
      xlim=c(0.2,2)  
      #ylim = c(0,0.44)  
      )
```



```
#Defino la moda
mean(v3)
```

```
## [1] 0.7979397
```

```
library(multimode)
```

```
## Warning: package 'multimode' was built under R version 4.4.2
```

```
modas<- locmodes(sqrt(v3),
                  mod0 =5) # Localiza la moda
```

```
## Warning in locmodes(sqrt(v3), mod0 = 5): If the density function has an
## unbounded support, artificial modes may have been created in the tails
```

```
modas
```


```
##
## Estimated location
## Modes: 0.5861264 0.8353957 1.012328 1.423014 2.208252
## Antimodes: 0.8017159 0.9029492 1.365739 2.20127
##
## Estimated value of the density
```

```

## Modes: 1.844465 1.104948 1.46284 0.2516582 0.0001556416
## Antimodes: 1.095612 1.034233 0.2254498 0.000155611
##
## Critical bandwidth: 0.05451965

plot(modas)

```



$N = 53940$  Critical bandwidth = 0.05452


#Subjetivamente ¿ Dónde estarían los estadísticos clásicos?

```

hist(sqrt(v3),
  breaks=85,main = "Peso",
  #xlab = "$",
  ylab="Frecuencia",
  prob = TRUE,
  col="lightpink",
  xlim=c(0.2,2)
  #ylim = c(0,0.44)
  )
#Graficamos cada estadistico




abline(v = mean(v3), col = 3) # Línea para media aritmética.
abline(v = median(v3), col = 2, lwd = 3) # Línea para mediana.
abline(v=modas[[1]], col = 4, lwd = 3) # Línea para la Moda

```




```
#Aplicaremos algunos métodos para los intervalos: #'Sturges", "Scott" y "freedman-diaconis"
#Metodo Sturges
par(mfrow = c(2, 2)) # Desplegamos 4 paneles
hist(v3, breaks="sturges", main = "Peso en Quilates",
      xlab = "Quilates",
      ylab="Frecuencia",
      col="pink", #ylim = c(0,0.44)
      )
#Freedman-Diaconis
hist(v3, breaks="fd", main = "Peso en Quilates",
      xlab = "Quilates",
      ylab="Frecuencia",
      col="purple",
      #ylim = c(0,0.44)
      )
#Scott
hist(v3, breaks="scott", main = "Peso en Quilates",
      xlab = "Quilates",
      ylab="Frecuencia",
      col="yellow",
      #ylim = c(0,0.44)
      )
#¿Con cuál nos quedamos?
#Teniendo en cuenta los datos de esta variable, podemos ver que tanto en metodo Scott o el
#Freedman-Diaconis, reflejan la informacion, graficamente de manera similar, por tanto
#cuálquiera de estos, cumplirían, mejor con la muestra grafica, que la opción de Sturges.
```

```
#Por ejemplo si optamos por el metodo Scott:
par(mfrow = c(1,1))
```



```
hist(v3, breaks="scott", main = "Peso en Quilates",
      xlab = "Quilates",
      ylab="Frecuencia",
      col="orange",
      xlim = c(min(v3),max(v3))
      #ylim = c(0,0.44)
    )
abline(v = mean(v3), col = 2, lwd = 3) # Línea para media aritmética.
abline(v = median(v3), col = 1, lwd = 3) # Línea para mediana. modas
abline(v =modas[[1]], col = 4, lwd = 3) # Línea para la Moda.
```

## Peso en Quilates




#En este punto podemos ver que ni la media, ni la mediana ni 1 sola moda, representan correctamente, #lo que necesitamos. Veamos si podemos exponer mas informacion, de estos datos, aplicando logaritmo.


```
par(mfrow=c(1,2))
hist(log(v3), breaks="sturges",
  main = "Pesos en Quilates",
  xlab = "Peso en Quilates",
  ylab="Frecuencia", col="pink",
  #ylim = c(0,0.44)
  )

hist(log(v3), breaks="fd",
  main = "Pesos en quilates",
  xlab = "Peso en Quilates",
  ylab="Frecuencia",
  col="purple",
  #ylim = c(0,0.44)
  )
```

**Pesos en Quilates**




**Pesos en quilates**



```
hist(log(v3), breaks="scott",
  main = "Pesos en quilates",
  xlab = "Peso en quilates",
  ylab="Frecuencia",
  col="lightblue",
  #ylim = c(0,0.44)
)
```


## Pesos en quilates



```
# Definitivamente, ni la media ni la mediana y una sola moda no la representa. Sera multimoda,  
#por ejemplo. Calculemos las más significativas.
```



```
par(mfrow=c(1,1))  
modas<-locmodes(log(v3), mod0 = 2)      #Localiza la moda  
  
## Warning in locmodes(log(v3), mod0 = 2): If the density function has an  
## unbounded support, artificial modes may have been created in the tails  
  
modas  
  
##  
## Estimated location  
## Modes: -1.096237  0.02928309  
## Antimode: -0.4948739  
##  
## Estimated value of the density  
## Modes: 0.6085034  0.6599266  
## Antimode: 0.4330636  
##  
## Critical bandwidth: 0.1421509
```

```
plot(modas)
```




```
par(mfrow = c(1, 2)) #Desplegamos 2 paneles
hist(log(v3),breaks="scott",
      main = "Peso en quilates",
      xlab = "peso en quilates",
      ylab="Frecuencia",
      col="violet",
      ylim = c(0,0.44)
    )
abline(v = mean(log(v3)), col = 3, lwd = 3) #Linea para media aritmética.
abline(v = median(log(v3)), col = 2, lwd = 3) #Linea para mediana.
abline(v =modas[[1]][1], col = 5, lwd = 3) #Linea para la Moda 1.
abline(v =modas[[1]][3], col = 1, lwd = 3) #Linea para la Moda 2.
plot(modas)
```

## Peso en quilates




```
# Pero para comparar, mejor en la misma escala los dos gráficos.
hist(log(v3), breaks="scott",
      main = "Peso en quilates",
      xlab = "peso en quilates",
      ylab="Frecuencia",
      prob=TRUE, #Añadimos esta función.
      col="lightblue",
      ylim = c(0,1)
)
abline(v = mean(log(v3)), col = 3, lwd = 5) # Línea para media aritmética.
abline(v = median(log(v3)), col = 2, lwd = 2) # Línea para mediana.
abline(v = modas[[1]][1], col = 5, lwd = 3) # Línea para la Moda 1.
abline(v = modas[[1]][3], col = 6, lwd = 3) # Línea para la Moda 2.
```

## Peso en quilates



```
plot(modas)
```



$N = 53940$  Critical bandwidth = 0.1422

```
par(mfrow=c(1,1))
plot(modas) #Como estadísticos de tendencia central tenemos dos valores:
# según la moda:
modas
```

```
##
## Estimated location
## Modes: -1.096237  0.02928309
## Antimode: -0.4948739
##
## Estimated value of the density
## Modes: 0.6085034  0.6599266
## Antimode: 0.4330636
##
## Critical bandwidth: 0.1421509
```

```
mean(log(v3))
```

```
## [1] -0.394967
```

```
# Calculemos otros estadísticos de dispersión.
rg=max(log(v3))-min(log(v3)) # Rango
rg
```

```
## [1] 3.220874
```

```

var(log(v3)) # Varianza

## [1] 0.3420232

sd(log(v3)) # Desviación estándar

## [1] 0.5848275

library(moments) # Librería para el cálculo de los momentos.
skewness(log(v3)) #Asimetría

## [1] 0.09610032

kurtosis(log(v3)) #Curtosis

## [1] 1.935102

#Obtenidos estos valores, podemos decir
#1)Segun el valor de Varianza, indica que los datos estan relativamente dispersos, aunque
#no de forma excesiva. Estan alejados de la media, por tanto descartamos dicho estadistico.
#2)La desviacion estandar, es la raiz cuadrada de la varianza. En este caso sugiere una
#dispersion moderada.
#3)En el caso, de la Asimetria, podemos decir que en este caso, es casi simetrica, porque
#el valor es cercano a cero, con una leve inclinacion, a derecha (asimetria positiva).
#4)Por ultimo, la curtosis, en este caso, es inferior a 3,por tanto indica una curtosis
#leptocurtica, esto sugiere que hay menos datos extremos.

#Hasta aqui podemos decir, que esta variable parece tener una distribucion moderadamente
#dispersa, con ligera asimetria positiva, lo que indica que los valores estan distribuidos
#de manera bastante equilibrada, hay menos valores extremos. # Elijamos una muestra del
#total de valores disponibles, aplicando un método de muestreo y repitamos los cálculos
#previos y verificamos si son consistentes o no.

```

## Muestreo Simple.

```

length(v3) # Total de datos disponibles: 53940.

## [1] 53940

# Selección de la muestra
n<-length(v3)*0.4 # Tamaño de la muestra. 40%
n

## [1] 21576

```


```

# Elegimos una muestra de forma aleatoria de los 53940. Para ello, hacemos uso de
v4<- sample(log(v3),size=n,replace=FALSE)

# Gráfico de la muestra "v4" y comparamos con el original.
hist(v4, breaks="scott",
      main = "Distribución de la muestra ",
      xlab = "Log(Peso en Quilates) [Q]",
      ylab = "Frecuencia",
      ylim=c(0,1.5), prob=TRUE,           #Añadimos esta función.
      col="red")   # Nuestro gráfico original, con toda la muestra.

```

## Distribución de la muestra




```

hist(log(v3), breaks="scott",
      main = "Distribución de todos los datos",
      xlab = "Log(Peso en Quilates) [Q]",
      ylab="Frecuencia", prob=TRUE,           #Añadimos esta función.           col="blue",
      ylim = c(0,1.5)
)

```

## Distribución de todos los datos



```
#En este caso, podemos quedarnos con la muestra, ya que al ver la comparacion,
```

```
#Definimos los estadisticos, nuevamente con respecto a la muestra.
```

```
mean(v4) # Media aritmética.
```

```
## [1] -0.3942149
```

```
median(v4) # Mediana.
```

```
## [1] -0.3566749
```

```
library(multimode)
modas <- locmodes(sqrt(v4), mod0 = 2) #Localiza las modas
```

```
## Warning in sqrt(v4): Se han producido NaNs
```

```
## Warning in locmodes(sqrt(v4), mod0 = 2): Missing values were removed
```

```
## Warning in locmodes(sqrt(v4), mod0 = 2): If the density function has an
## unbounded support, artificial modes may have been created in the tails
```


```

modas

## 
## Estimated location
## Modes: 0.1723136 0.4227817
## Antimode: 0.3477961
## 
## Estimated value of the density
## Modes: 1.113053 1.055863
## Antimode: 1.052975
## 
## Critical bandwidth: 0.1166687

```

```
plot(modas)
```



$N = 7618$  Critical bandwidth = 0.1167

```
var(v4) # Varianza.
```

```
## [1] 0.3400066
```

```
sd(v4) #Desviación est{\'a}ndar.
```

```
## [1] 0.5831009
```

```
skewness(v4) #Asimetria.
```

```
## [1] 0.09467696
```

```
kurtosis(v4) #Curtosis.
```

```
## [1] 1.928556
```

## Conclusiones Ejercicio 1:

# Con respecto a la Variable discreta "Clarity" SI1 es el nivel de claridad más común en el conjunto de datos. Esto sugiere que una proporción significativa de los diamantes tiene pequeños defectos que son "ligeramente incluidas" (Slightly Included 1). #SI1 suele encontrarse en una calidad intermedia entre diamantes de muy alta calidad #(como IF, VVS1/VVS2) y aquellos con imperfecciones más visibles (como I1, I2).

#Esto podría indicar que los diamantes del dataset están orientados a un mercado de calidad media, donde SI1 ofrece una buena relación entre precio y apariencia.

#Con la herramienta del grafico con el metodo de Pareto, podemos confirmar, que #la mayor concentracion de diamantes, son aquellos que estan catalogados, como SI1, #es decir, para este grupo de datos analizados, podemos decir, que la mayor cantidad #de diamantes son aquellos, de calidad media, o con defectos, poco visibles, seguido #de aquellos agrupados en la categoria VS2, que como los anteriores, representan a aquellos, #con ligeros defectos.

# Con respecto a la Variable continua "Carat" : Las modas representan los valores más #frecuentes. En este caso, se encuentran en dos puntos diferentes, lo que sugiere que #la distribución podría ser bimodal, es decir, hay dos valores en los que los datos #se agrupan con mayor frecuencia. En este caso, ambos son bastante cercanos, lo que #sugiere que las modas son puntos con alta concentracion de datos. Análisis de la otros #estadisticos: Varianza (0.3441411): En este caso, una varianza moderada indica que #los valores de "Carat" no están excesivamente dispersos ni muy concentrados alrededor #de la media. Desviación estándar (0.5866354): es relativamente baja en comparación con #el rango. Esto indica que los datos no se desvían demasiado de la media.

#Asimetria(0.09669699): Es cercana a 0, lo que indica que la distribución es casi simétrica. #No hay una tendencia clara hacia un sesgo positivo o negativo en los datos.

#Curtosis (1.921081): La curtosis es menor que 3, lo que indica que la distribución #tiene colas más ligeras que una distribución normal. Esto puede sugerir que los valores #extremos (outliers) son menos frecuentes en comparación con una distribución normal.

#Análisis de Region crítica(0.1091385): Podría indicar la suavidad de la estimación.

#Una region crítica relativamente pequeña sugiere que la estimación de la densidad #está más ajustada a los puntos de datos y podría no ser tan suave. Es decir, podría #haber dos grupos distintos o características con mayor frecuencia en los datos.

#Los datos están relativamente dispersos alrededor de un valor central.

#La curtosis sugiere que la distribución tiene colas ligeras, lo que significa que #no hay una presencia significativa de valores extremos. El valor de la region crítica #podría indicar que la estimación de la densidad se ajusta bien a los datos. En conclusion, #la variable "Carat" muestra una distribución con dos grupos diferentes de datos mas #frecuentes, no muestra una alta concentración en torno a un único valor, #sino más bien una dispersión moderada con pocas colas extremas.

## Ejercicio 2 (L-moments)

#Los L-Moments, son otros estadísticos alternativos que nos permiten estudiar ciertas distribuciones que se pueden considerar con colas muy pronunciadas, donde los momentos clásicos no logran adaptarse bien. Es decir, caracterizan mejor la distribución ya que son menos sensibles en los extremos. Para una variable estadística aleatoria  $X$  están definidos en términos de los ordenes estadísticos ( $p$ -ésimos) tal que:

```
install.packages("evd")
```

```
## Installing package into 'C:/Users/lulia/AppData/Local/R/win-library/4.4'  
## (as 'lib' is unspecified)
```

```
## package 'evd' successfully unpacked and MD5 sums checked  
##
```

```
## The downloaded binary packages are in  
## C:\Users\lulia\AppData\Local\Temp\RtmpSOY0Iy\downloaded_packages
```

```
install.packages("lmom") #Cargo librerias necesarias
```

```
## Installing package into 'C:/Users/lulia/AppData/Local/R/win-library/4.4'  
## (as 'lib' is unspecified)
```

```
## package 'lmom' successfully unpacked and MD5 sums checked  
##
```

```
## The downloaded binary packages are in  
## C:\Users\lulia\AppData\Local\Temp\RtmpSOY0Iy\downloaded_packages
```

```
library(lmom)  
library(Lmoments)
```

```
## Warning: package 'Lmoments' was built under R version 4.4.2
```

```
library(evd)
```

```
## Warning: package 'evd' was built under R version 4.4.2
```

#Simulo un conjunto de datos, de ejemplo, para la distribucion GUMBEL, que se encuentra en ambas librerias.

```
set.seed(123) #Reproducibilidad
```

```
n<-100
```

```
data_gumbel<- rgumbel(n,loc=0, scale=1)
```

#Calculo los L-Moments con cada libreria

#Con la libreria lmom:

```
lmom_lmom<-samlmu(data_gumbel)
```

```
lmom_lmom
```

```
##      l_1      l_2      t_3      t_4  
## 0.4802932 0.6613717 0.2200150 0.1761222
```

```

#Con la libreria L-moments
lmom_Lmoments<-Lmoments(data_gumbel)
lmom_Lmoments

##           L1          L2          L3          L4
## [1,] 0.4802932 0.6613717 0.1455117 0.1164822

#Creo un dataframe para comparar los resultados
comparacion<-data.frame(Momentos = c("L1 (media)","L2(varianza)","L3(Asimetria)","L4(curtosis)"),
                          lmom=lmom_Lmom,
                          Lmoments=lmom_Lmoments)
print(comparacion)

##           Momentos      lmom Lmoments.L1 Lmoments.L2 Lmoments.L3 Lmoments.L4
## l_1     L1 (media) 0.4802932 0.4802932 0.6613717 0.1455117 0.1164822
## l_2     L2(varianza) 0.6613717 0.4802932 0.6613717 0.1455117 0.1164822
## t_3     L3(Asimetria) 0.2200150 0.4802932 0.6613717 0.1455117 0.1164822
## t_4     L4(curtosis) 0.1761222 0.4802932 0.6613717 0.1455117 0.1164822

#Conclusion ejercicio 2:
#La distribucion Gumbel, es de alta presicion, por tanto en este caso elegiria trabajar
#su analisis con la libreria "lmom". Aun asi podemos ver que con ambas librerias,
#se obtienen datos similares y consistentes. Como momentos mas relevantes en este caso,
#podemos decir que serian el momento L3 (Asimetria), ya que permite evaluar el sesgo
#de la distribucion, y el L4 (Curtosis), que describe la prominencia de valores extremos.
#Por lo tanto, estos momentos son los mas utiles para representar adecuadamente
#las caracteristicas de esta distribucion.

```